

GraphMem 与 Mem0 准确率、Token 开支与核心创新

LongMemEval 与 LoCoMo 的同题评测、memory-backbone 成本拆分，以及 Hierarchical Navigable Memory World 和 Graph Harness Query IR 的机制说明。

LongMemEval • 500题

89.00%

较 Mem0 +18.80 pp

LoCoMo • Category 1-4

86.23%

较 Mem0 +7.34 pp

平均回答 Token


**7.03K /
4.41K**

LongMemEval / LoCoMo

报告成本单位

LongMemEval 构建按每题对应的一份 memory 计算；LoCoMo 构建按每个 conversation 计算；两个 benchmark 的回答成本均按每题计算。Embedding 与 judge token 全部排除。

1. 准确率：同题官方 Judge 对比



LongMemEval 配对结果

两者都正确	316
仅 GraphMem 正确	129
仅 Mem0 正确	35
两者都错误	20

LoCoMo 配对结果

两者都正确	1,088
仅 GraphMem 正确	240
仅 Mem0 正确	127
两者都错误	85

LoCoMo 的 convN_qM 与 locomoNN_MMMM 完整对齐 1,540 题，缺失 0。准确率差的配对 bootstrap 95% 区间为 +4.94 至 +9.68 pp；McNemar 双侧精确检验 $p=3.82 \times 10^{-9}$ 。

2. 分类型表现：优势与剩余短板

LongMemEval

题型	GraphMem	Mem0	差值
Knowledge update	87.18%	79.49%	+7.69 pp
Multi-session	88.72%	68.42%	+20.30 pp
Assistant fact	96.43%	85.71%	+10.71 pp
Preference	93.33%	96.67%	-3.33 pp
User fact	94.29%	92.86%	+1.43 pp
Temporal reasoning	83.46%	42.11%	+41.35 pp

LoCoMo Category 1-4

Category	GraphMem V3.4	Mem0	差值
Category 1	83.33%	65.96%	+17.38 pp
Category 2	80.69%	83.80%	-3.12 pp
Category 3	57.29%	65.63%	-8.33 pp
Category 4	92.63%	82.88%	+9.75 pp
Overall	86.23%	78.90%	+7.34 pp

结构性优势

LongMemEval 的 temporal 与 multi-session 增益最强，符合状态链、时间端点和跨会话证据装配的设计目标。

剩余短板

LoCoMo Category 2/3 仍低于 Mem0，复杂多跳、指代闭包和回答推理仍有提升空间。

附件 Mem0 的原始 67.02% 包含 446 道 Category 5；同分母对比应使用 Category 1-4 的 78.90%。

3. Token 开支：统一到正确计算单位

计算口径：构建成本只在 memory 创建时发生。LongMemEval 每题有独立 memory，因此按题计算；LoCoMo 只有 10 组共享 conversation，因此按 conversation 计算。回答成本均按问题数计算。

LongMemEval • 构建 Token / 题（500份独立 memory）

项目	全量	每题平均	分布
Uncached input	63,056,006	126,112	P50 253,946 P95 271,194
Cached input	18,749,824	37,500	Max 284,693
Output	45,446,463	90,893	
Total	127,252,293	254,505	

LoCoMo • 构建 Token / conversation（10组）

项目	10组全量	每组平均	分布
Uncached input	772,479	77,248	P50 139,922 P95 150,802
Cached input	4,864	486	Max 150,802
Output	546,158	54,616	
Total	1,323,501	132,350	


回答 Token / 题

Benchmark	Uncached	Cached	Output	Total / 题	分布
LongMemEval	5,428	1,580	23	7,031	P50 7,020 • P95 8,000 • Max 8,725
LoCoMo	3,238	1,046	129	4,413	P50 4,405 • P95 5,055 • Max 5,834

LoCoMo 的构建成本摊销到 1,986 个问题为 666 token/题；构建+回答合计平均 5,079 token/题。该摊销值用于理解复用收益，不替代“构建按 conversation、回答按题”的主报告口径。

4. 创新一：Hierarchical Navigable Memory World

HNMW 将长期对话构造成可复用、可逐层定位、可沿关系导航并最终回溯原文的持久化记忆世界。其目标不是存储更多副本，而是让每次查询只读取最小完备证据。



Hierarchical

卡片 → Frame → 原文

粗层只做定位，细层承载答案事实。

Navigable

Typed relation 横向补证

状态、时间、问答和指代按需扩展。

Reusable

一次构建，多题查询

LoCoMo构建在1,986题间共享。

状态更新案例


周一：“计划坐火车去上海” → 周三：“取消火车票” → 周三：“已预订周四航班”。

问题“现在准备如何去上海？”先定位旅行卡片，沿状态链保留 train planned→cancelled 和 flight booked，再展开两条原文核验。系统不重放完整 transcript，也不会把旧计划误当前状态。

HNMW解决“在哪里找、如何少读、如何复用”；它不意味着首次构建零成本。

5. 创新二：Graph Harness Query IR

Query IR 将自然语言问题编译为可执行的证据契约，让 dense、BM25、倒排索引、图遍历和 operator 围绕同一组 required roles 工作。



查询需求	Required roles	允许的补证路径
当前状态	旧值、新值、操作、时间、source	state transition → source
时间比较	事件A/B、时间A/B、source	same event / temporal endpoint
数量与列表	范围、成员、add/remove、source	collection member → source
双人对话	提问者、回复者、回复内容	dialogue pair / next turn

时间比较案例
问题：“活动 A 比活动 B 早多少天？” Required roles = 事件A + 时间A + 事件B + 时间B + source。
如果只命中A，系统只能沿 same_event / temporal_endpoint 补齐B；四项证书完整后才允许日期差 operator。最终LLM负责表达，但不得改写已认证日期差。

Query IR解决 “要找齐什么、允许沿哪些边走、什么时候停止、如何证明证据足够”。

6. 结论、边界与复现

可公开结论

- LongMemEval: GraphMem 89.00%, Mem0 70.20%, 提升 18.80 pp。
- LoCoMo Category 1-4: GraphMem 86.23%, Mem0 78.90%, 提升 7.34 pp。
- 回答平均: LongMemEval 7,031 token/题, LoCoMo 4,413 token/题。
- LoCoMo 每 conversation 构建平均 132,350 token, 可由1,986题复用。

必须保留的边界

- LongMemEval 首次构建平均 254,505 token/题, 并不便宜。
- Mem0附件没有 memory ingestion/search/answer usage, 不能声明具体Token节省百分比。
- 18.80 pp 是完整系统差异, 不能全部归因于 Query IR 单模块。
- LoCoMo Category 2/3 仍是 GraphMem 短板。

两个创新的组合价值

HNMW 把海量历史压缩成可复用、可导航的小工作集, 负责“少读”; Graph Harness Query IR 把问题变成证据角色契约, 负责“读对”。组合目标不是召回更多节点, 而是用最少 token 构造 source-complete 的最小完备证据子图。

复现产物

LongMemEval 89%	runs/v3_7_hybrid_20260730/lme500_v2ledger_gpt54mini/
LoCoMo V3.4	runs/v3_full_20260727/locomo_full1986_lossless_nav_v34/
LoCoMo构建索引	runs/v3_full_20260727/locomo_full1986_base/hierarchical_hypergraph_v3/
完整文字报告	docs/graphmem_mem0_comprehensive_report_20260804.md

下一步严格实验

- 为 Mem0 的 add/search/answer 增加 usage interceptor, 获得对称的 cached、uncached、output 统计。
- 固定索引与回答模型, 依次消融 typed edge、Query IR allowlist、role-gap expansion 与 evidence certificate。